

面向障碍环境多目标点遍历路径规划的协同优化框架

作者姓名 *Member, IEEE*

摘要—自主导航要求移动机器人在障碍物环境中以最优顺序访问一系列目标点，这一多目标点遍历路径规划问题在无人公交接驳、物流配送和基础设施巡检等场景中至关重要。该问题同时耦合两个子问题：一是在杂乱环境中寻找点对之间的无碰撞路径，二是确定目标点的最优访问顺序。现有研究往往只处理其中一个子问题——旅行商求解器默认欧氏距离，路径规划器则只优化单点对之间的路由。针对这一空白，本文提出一种将两者统一的协同优化框架。首先，基于跳点搜索（Jump Point Search, JPS）的改进 A* 全局规划器将障碍信息编码为旅行商代价矩阵，JPS 利用栅格对称性跳过冗余节点扩展；随后结合安全感知的路径简化（拐点提取、贪心扫描与中间点探索）以及弧长参数化三次样条平滑。所得开放旅行商问题（起点与终点固定且不重合）由一种改进蚁群优化算法求解：通过虚拟节点法将其转化为闭环旅行商问题，并融合最大-最小蚁群系统的信息素管理、蚁群系统的伪随机转移规则、候选列表加速的可变邻域下降局部搜索，以及 S 形渐进调度和自适应停止准则。在三个测试环境上的实验表明，基于 JPS 的规划器相较 Dijkstra 最多减少 83% 的节点扩展、搜索速度提升约 17 倍，并生成更短的路径；参数敏感性分析确定了一组均衡默认配置；消融实验表明可变邻域下降局部搜索与最大-最小蚁群系统信息素边界是保证求解质量的关键组件；所提出的求解器在 kroB100 基准上以 97.5% 的命中率达到最优代价，显著优于标准蚁群优化、遗传算法和模拟退火，并表现出更高的稳定性。

Index Terms—多目标点遍历，路径规划，跳点搜索，蚁群优化，开放旅行商问题，避障，虚拟节点法

I. 引言

多目标点遍历路径规划是自主移动机器人领域的一项基本问题，在无人公交接驳、物流仓储管理、基础设施巡检以及搜救行动等场景中具有广泛应用 [1], [2]。在完成例如接送乘客、检查设备、投递物品等特定任务中，机器人需要从指定起始位置出发，依次访问一系列中间目标点，最终到达目标终点。规划器需解决两个既独立又耦合的子问题：

(1) 在杂乱环境中寻找连续点对之间的无碰撞路径；

(2) 确定中间目标点的最优访问顺序。第一个子问题属于几何问题——需要在物理空间中对障碍物几何形状和路径连续性进行推理。第二个子问题属于组合优化问题——是经典 NP-hard 旅行商问题（TSP）的一个实例。这两个子问题相互影响，任意两点之间的通行代价取决于其间存在的障碍物，而最优访问顺序又取决于这些点对间的通行代价。

总体来看，现有多目标导航方法通常仅独立处理其中一个子问题。大量旅行商问题研究假设点对间的代价由欧氏距离或已知距离矩阵给出 [3], [4]，忽略了在障碍物丰富的环境，两点之间的最短无碰撞路径可能远长于直线距离这一事实。另一方面，例如 A*、Dijkstra、快速扩展随机树（RRT）及其变体路径规划领域的成熟算法能够高效地计算栅格地图中点对之间的最优或近似最优无碰撞路径，但这些规划器并不优化多目标点的访问顺序 [5]–[7]。少量研究在特定几何假设下探索了带障碍物的旅行商问题变体（如带障碍物的 TSP、Dubins TSP），但目前尚缺乏一种将基于栅格的全局规划器与高性能旅行商求解器相集成的、通用的障碍环境多目标点遍历框架。

针对上述约束并最大化利用两类算法的优势，本文旨在提出一种面向障碍环境多目标点遍历路径规划的协同优化框架。该框架由两个算法层组成，通过预计算的代价矩阵连接。第一层是基于跳点搜索（JPS）的改进 A* 全局规划器，其利用栅格对称性跳过冗余节点扩展、仅扩展跳点，从而大幅缩减搜索树规模；该规划器结合了安全感知的路径简化流程（含拐点提取和中间点探索）以及弧长参数化三次样条平滑管线。第二层是面向开放旅行商问题的改进蚁群优化（ACO）求解器，其通过虚拟节点（哑节点）法将开放旅行商问题转化为标

准闭环旅行商问题,从而充分利用闭环旅行商问题的搜索算子;该求解器融合了最大-最小蚁群系统(MMAS)的信息素管理、蚁群系统(ACS)风格的伪随机转移规则、以 k 近邻候选列表加速的可变邻域下降(VND)局部搜索引擎,以及基于S形函数的渐进式局部搜索调度和自适应停止准则。

本文的贡献分为三个层面:

- 1) 在问题层面,将障碍环境多目标点遍历形式化为一个集成优化任务,并提出通过全局规划器把障碍信息编码为旅行商代价矩阵的两层框架,从而弥合孤立路径规划与无约束旅行商研究之间的空白,使其适用于存在障碍物且起点、终点不重合的真实导航任务。
- 2) 在算法协同层面,引入具有安全检测的真实路径代价计算机制,在评估代价矩阵元素之前应用安全感知的路径规划运算,使旅行商代价函数更准确地反映真实连续路径长度,从而提升求解器区分不同访问顺序方案的能力;同时,模块化架构允许将任意栅格规划器与旅行商求解器替换到相应层中。
- 3) 在组件层面,路径规划方面采用跳点搜索剪枝冗余节点,并以安全感知路径简化生成最小安全航点子集;旅行商优化方面采用虚拟节点法使起点、终点完整参与信息素模型与局部搜索,以候选列表加速的可变邻域下降将局部搜索复杂度从 $O(K^2)$ 降至 $O(K \cdot k)$,并以S形渐进调度与自适应停止机制平衡探索、利用并节省计算。上述组件均通过消融实验得到独立验证。

本文其余部分组织如下:第II节综述全局路径规划、旅行商元启发式方法及带障碍物多目标点遍历的相关研究;第III节形式化问题定义;第IV节详述方法论,包括改进的A*规划器(第IV-A节)、路径后处理管线(第IV-B节)、改进的蚁群优化求解器(第IV-C节)和协同优化框架(第IV-D节);第V节报告四个评估维度的实验结果:全局路径规划对比、参数敏感性分析、消融实验以及不同旅行商求解器的多目标点遍历对比;第VI节总结全文并展望未来工作。

II. 相关工作

A. 栅格环境中的全局路径规划

全局路径规划旨在已知静态环境中寻找两点之间的无碰撞路径。经典图搜索算法仍是栅格规划的主流方

法。Dijkstra算法保证最短路径,但以均匀方式向所有方向扩展,在大地图上效率较低[6]。A*算法通过引入启发式函数 $h(n)$ 引导搜索方向,同时在 $h(n)$ 可采纳时保持最优性[5]。然而,标准A*使用固定的启发式权重,面临权衡困境:权重为1时保证最优性但扩展节点过多,较大的常数权重可加速搜索但牺牲路径最优性。若干A*变体针对此局限进行了改进[8]。加权A*将启发式乘以常数因子 $\epsilon > 1$,以更快的速度产生 ϵ -最优解[9]。任意时间修复A*及其后续方法交替进行加权和无加权搜索,生成逐步改进的解序列[10]。然而,这些方法在整个搜索过程中施加统一权重,而最优权重直观上取决于到目标的距离:远离目标时激进权重有利,接近目标时需要精度。跳点搜索(JPS)利用栅格对称性跳过冗余节点,仅扩展最优路径改变方向或遇到强制选择的跳点[11], [12]。我们的基于JPS的规划器(第IV-A节)采纳了这一原理,近期的JPS变体进一步通过双向搜索和任意角度路径精化提升了效率[13]–[15]。

基于采样的规划器如快速扩展随机树(RRT)[7]和概率路线图(PRM)提供概率完备性,在高维构型空间中表现良好,但其在栅格环境中的解路径通常比图搜索方法更长、一致性更差,这是由于随机采样的固有特性所致。

栅格路径的后处理是成熟的技术实践。路径裁剪方法通过共线性检查或视线验证移除冗余共线航点[16]。路径平滑方法包括三次样条、B样条和回旋曲线等,将离散航点序列转化为适合机器人执行的连续曲线[17], [18]。然而,裁剪和平滑通常被视为独立的事后步骤;将它们集成到代价矩阵计算中——即用简化路径长度指导组合优化——是我们框架的一个显著特征。

B. 旅行商问题的元启发式方法

旅行商问题是组合优化领域中研究最为深入的问题之一。基于分支定界或动态规划的精确算法仅适用于小规模实例(通常 $K \leq 20$),这源于搜索空间的阶乘级增长。对于更大规模的实例,元启发式方法是首选方案。

遗传算法(GA)将路径编码为染色体,应用交叉算子(如顺序交叉OX)和变异算子,通过锦标赛或轮盘选择挑选最优个体[19]。模拟退火(SA)通过邻域移动(通常为2-opt交换)探索解空间,并以随退火计划衰减的概率接受劣化解,从而逃脱局部最优[20]。

蚁群优化(ACO)是一种受蚂蚁觅食行为启发的种群元启发式方法。在基本蚁群系统中,蚂蚁根据信息素

轨迹和启发式可见度概率性地构建路径，并在其路径上沉积信息素以引导后续世代 [21]。蚁群系统通过伪随机比例转移规则扩展了基本蚁群系统，在贪心利用与概率探索之间取得平衡，提高了收敛速度 [22]。最大-最小蚁群系统通过施加信息素值的显式上下界进一步稳定搜索过程，防止对次优解的过早收敛，同时在低频边上保持探索多样性 [23]。

局部搜索混合化在蚁群优化中已被证明非常有效。对每一代最优解应用 2-opt、3-opt 或可变邻域下降 (VND) 可显著提升解质量 [24], [25]。然而，VND 对每个邻域算子评估 $O(K^2)$ 个候选移动，在 $K > 100$ 时成为计算瓶颈。候选列表技术通过将评估限制于节点的最近邻来加速局部搜索，已被广泛采用 [26]。我们的候选列表加速 VND (第 IV-C4 节) 通过预计算的 k 近邻列表剪枝无前景的评估，将复杂度降至 $O(K \cdot k)$ ，使大规模实例的局部搜索变得可行。

渐进式局部搜索调度在文献中受到的关注较少。大多数蚁群优化实现在整个运行过程中对固定比例的蚂蚁施加局部搜索。近期的蚁群优化变体强调并行化、小生境化和面向可持续性的机制，以应对大规模实例 [27]–[30]。我们的 S 形调度 (第 IV-C5 节) 在迭代预算内将局部搜索比例从零递增至最大值，匹配了从早期探索主导到后期精化主导的自然转变。

C. 带障碍约束的多目标点遍历

路径规划与旅行商优化的交叉领域已在多个名义下得到探索 [4]。带障碍物的旅行商问题 (TSPO) 考虑连续平面中的一组多边形障碍物，寻求访问所有目标点且不与障碍物相交的最短路径 [3]。其解通常通过计算可见图并在所得图上求解旅行商问题。Dubins 旅行商问题将问题扩展至具有最小转弯半径约束的车辆。邻域旅行商问题将目标从点泛化为区域，要求路径至少访问每个区域一次。这些公式依赖于连续几何表示 (多边形、圆盘) 并假设特定的障碍形状，限制了其在基于栅格的机器人导航中的适用性——在栅格导航中，障碍物以任意占用模式表示。

结合路径规划器与旅行商求解器的两层架构已有若干先例 [1], [2]。例如，概率路线图被用于构建连通图，并在其上以采样构型间的最短路径距离求解旅行商问题。然而，这些方法通常采用现成的规划器和求解器，未针对多目标点遍历上下文优化任一层。代价矩阵由原始栅格路径计算得出，因离散化伪影而高估了真实路径

长度，且旅行商求解器缺乏我们框架所提供的问题特定增强 (如开放旅行商编码、候选列表加速)。

开放旅行商变体——其中起点和终点为不重合的固定位置——与自主导航任务尤为相关，机器人从仓库出发并到达目的地。经典旅行商问题文献的大部分内容，包括大多数 TSPLIB 基准实例，针对的是闭环旅行商问题。开放旅行商问题需要不同的编码和代价评估函数，我们在第 III-B 节中将其形式化，并在第 IV-C1 节中通过虚拟节点 (哑仓库) 法给出算法实现，该方法类似于开放车辆路径问题中所采用的技术 [31], [32]。

综上，A* 类方法可给出高质量的点对点路径，开放式旅行商元启发式则擅长组合排序，二者单独使用均难以覆盖障碍环境下的完整多目标点遍历任务。将基于跳点搜索的全局规划、安全感知后处理与开放旅行商蚁群优化相集成，可在保留几何可行性的同时提升访问顺序优化的质量。据我们所知，尚无先前工作同时满足以下三点：(1) 基于跳点搜索的改进栅格全局规划器与安全感知路径后处理；(2) 融合候选列表加速 VND 和 S 形渐进局部搜索的开放旅行商蚁群优化求解器；(3) 利用简化路径代价实现精确组合优化的协同代价矩阵接口。因此，本文提出了相应的协同优化框架。

III. 问题形式化

本节将障碍环境多目标点遍历路径规划问题进行形式化定义。首先建立基于栅格的环境模型，然后定义具有固定起点和终点的开放旅行商问题，最后给出完整的优化目标。

A. 栅格地图与障碍物表示

运行环境建模为 $n \times n$ 单元的二维方形栅格地图。每个栅格单元被分类为自由空间或障碍物：

$$\mathbf{M}(r, c) = \begin{cases} 0, & \text{栅格}(r, c) \text{ 为自由空间} \\ 1, & \text{栅格}(r, c) \text{ 被占用} \end{cases} \quad (1)$$

其中 $r \in \{1, \dots, n\}$ 和 $c \in \{1, \dots, n\}$ 分别为行索引和列索引。假设地图在规划前静态且完全已知。

相邻自由栅格之间的移动遵循 8 邻域连通性：从栅格 (r, c) 可向其周围 8 个相邻栅格 $(r + \Delta r, c + \Delta c)$ 移动，其中 $\Delta r, \Delta c \in \{-1, 0, 1\}$, $(\Delta r, \Delta c) \neq (0, 0)$ ，前提是目标栅格为自由空间。移动代价区分正交步和对角步：

$$\text{cost}(\Delta r, \Delta c) = \begin{cases} 1, & |\Delta r| + |\Delta c| = 1 (\text{正交步}) \\ \sqrt{2}, & |\Delta r| + |\Delta c| = 2 (\text{对角步}) \end{cases} \quad (2)$$

对于对角移动, 相邻的两个正交栅格也必须同时为自由空间; 否则机器人将穿越障碍物角点, 这对非点状机器人来说在物理上不可行。

栅格坐标 (r, c) 通过将栅格中心置于其几何中心处映射为连续世界坐标 (x, y) :

$$x = c - 0.5, \quad y = r - 0.5 \quad (3)$$

此映射将连续坐标系的原点置于栅格左下角 (栅格 $(1, 1)$ 映射为 $(0.5, 0.5)$), 与占用栅格地图中机器人定位的标准约定一致。

B. 具有固定起点和终点的开放旅行商问题

设任务规格包含一个起点 S 、 K 个中间目标点 $\mathcal{T} = \{T_1, T_2, \dots, T_K\}$ 和一个终点 G 。所有点以栅格坐标 $[r, c]$ 指定。完整点集定义为:

$$\mathcal{P} = \{p_1, p_2, \dots, p_N\}, \quad N = K + 2 \quad (4)$$

索引约定为: $p_1 = S$, $p_i = T_{i-1}$ ($i = 2, \dots, K+1$), $p_N = G$ 。起点和终点不重合, 占据任何可行解的边界位置。

一个有效路径由访问顺序 $\pi = (\pi_1, \pi_2, \dots, \pi_N)$ 定义, 该顺序是索引集 $\{1, 2, \dots, N\}$ 的排列, 满足边界约束:

$$\pi_1 = 1 \quad (\text{起点}), \quad \pi_N = N \quad (\text{终点}) \quad (5)$$

中间索引 $\{\pi_2, \dots, \pi_{N-1}\}$ 构成 $\{2, \dots, N-1\}$ 的一个排列, 表示目标点的有序访问。可行路径的总数为 $K!$, 对应中间目标点的所有排列且端点固定。这是**开放旅行商问题**的形式化, 区别于经典闭环旅行商问题——后者的路径构成环路且起始节点可任意选取 [3], [4]。

C. 优化目标

对于任意有序点对 (p_i, p_j) , 设 $\mathcal{P}(p_i, p_j)$ 表示从 p_i 到 p_j 在栅格地图 $\mathbf{M}$ 中的最短无碰撞路径, 由全局路径规划器计算。该路径为栅格单元序列:

$$\mathcal{P}(p_i, p_j) = [p_i = q_1, q_2, \dots, q_m = p_j], \quad (6)$$

$$q_k \in \{(r, c) \mid \mathbf{M}(r, c) = 0\}$$

路径长度为序列中各边代价之和:

$$L(\mathcal{P}(p_i, p_j)) = \sum_{k=1}^{m-1} \text{cost}(q_{k+1} - q_k) \quad (7)$$

其中 $\text{cost}(\cdot)$ 由式 (2) 定义。若 p_i 和 p_j 之间不存在无碰撞路径, 则 $\mathcal{P}(p_i, p_j) = \emptyset$, $L(\emptyset) = \infty$ 。

路径 π 的总代价为 $N-1$ 段连续路径长度之和:

$$C(\pi) = \sum_{k=1}^{N-1} L(\mathcal{P}(p_{\pi_k}, p_{\pi_{k+1}})) \quad (8)$$

障碍环境多目标点遍历问题表述为:

$$\pi^* = \arg \min_{\pi \in \Pi} C(\pi) \quad (9)$$

$$\text{s.t.} \quad \pi_1 = 1, \pi_N = N, \{\pi_2, \dots, \pi_{N-1}\} = \{2, \dots, N-1\}$$

$$\mathcal{P}(p_{\pi_k}, p_{\pi_{k+1}}) \neq \emptyset \quad \forall k \in \{1, \dots, N-1\}$$

其中 Π 为所有满足边界约束的 $\{1, \dots, N\}$ 排列的集合。式 (9) 中的优化耦合了两个相互作用的子问题: (1) 为每段路径寻找最短无碰撞路径 (几何问题, 由全局规划器求解); (2) 确定中间目标点的最优排序 (组合问题, 由旅行商求解器求解)。代价矩阵元素 $\mathbf{D}(i, j) = L(\mathcal{P}(p_i, p_j))$ 构成两个子问题之间的接口, 将完整的障碍约束距离拓扑编码为 $N \times N$ 矩阵。该解耦是精确的: 对于给定的代价矩阵 $\mathbf{D}$, 式 (9) 的优化退化为开放旅行商问题; 对于给定的访问顺序 π , 每段路径是独立的全局规划问题。

在特殊情况 $K = 0$ (无中间目标点) 下, 问题退化为单对最短路径查询: $\pi^* = (1, N)$, $C(\pi^*) = L(\mathcal{P}(S, G))$, 即经典单对路径规划问题。

IV. 方法论

为克服单一路径规划器无法优化访问顺序、以及无约束旅行商模型忽略障碍代价的局限, 本节提出一种由两个阶段组成的启发式协同框架。本章算法中的超参数均以符号给出, 除特别说明外默认取值统一列于表 I。具体而言, 第一阶段采用本文提出的改进 A* 全局规划器在栅格地图上搜索点对点无碰撞最短路径, 并通过安全距离感知的路径简化与三次样条平滑生成高

质量连续路径；第二阶段以该阶段输出的代价矩阵为输入，由本文提出的 MMAS-VND-CL 蚁群优化求解器求解多目标点的最优访问序列。两阶段通过代价矩阵实现耦合，共同完成从几何寻径到组合排序的完整流程。第 IV-A 节和第 IV-B 节介绍全局路径规划及后处理，第 IV-C 节详述开放旅行商求解算法，第 IV-D 节阐述两层协同框架的整体设计。

A. 改进的 A^* 全局路径规划器

1) 跳点搜索：传统 A^* 算法在搜索过程中需要扩展大量节点，尤其在大规模开阔区域中，节点扩展数量与地图面积成正比，计算效率受到严重制约。为解决这一问题，本文提出基于跳跃点搜索（Jump Point Search, JPS）的改进 A^* 算法 [11], [12]。JPS 的核心思想是利用栅格地图的对称性，在搜索过程中跳过大量冗余的中间节点，仅保留具有“跳跃意义”的关键节点作为扩展候选。

在传统 A^* 中，当前节点的所有邻居均需加入 open set 进行评估，而 JPS 通过邻居剪枝大幅减少需要考虑的邻居数量。具体而言，剪枝策略取决于当前节点的扩展方向：

- 1) **直线移动（水平或垂直）**：仅保留自然邻居（移动方向前方的节点）和被迫邻居（因障碍物阻挡而被迫改变方向的节点）。对于直线移动方向两侧的节点，除非被障碍物阻挡产生被迫邻居，否则均被剪枝。
- 2) **对角线移动**：保留自然邻居（对角方向前方）、直线方向的自然邻居（水平和垂直分量方向），以及因障碍物产生的被迫邻居。

被迫邻居的判定条件为：当前节点沿移动方向的相邻位置被障碍物阻挡，但沿另一方向可达。图 1 给出了剪枝规则的示意图。

进一步地，JPS 的跳跃函数 $\text{jump}(r, c, dr, dc)$ 从当前节点 (r, c) 出发，沿方向 (dr, dc) 逐步前进，直到满足以下三个终止条件之一：（1）到达目标节点；（2）遇到障碍物或地图边界（该方向不可通行）；（3）发现被迫邻居（当前位置因障碍物阻挡而需要强制转向）。跳跃过程中经过的中间节点不会被加入 open set，从而显著减少了节点扩展数量。当遇到被迫邻居时，当前节点即为跳跃点，需要加入 open set 进行后续评估。对于对角线方向的跳跃，算法会先沿对角线前进一步，然后分别沿水平和垂直分量方向执行直线跳跃。若任一方向的




图 1. JPS 邻居剪枝规则示意图。

直线跳跃发现了被迫邻居或到达目标，则返回当前对角线位置作为跳跃点。当 jump 函数返回可达的下一个节点后，还需要计算从当前节点到该跳跃点的实际移动成本。对于直线跳跃，成本等于跳跃的曼哈顿距离；对于对角线跳跃，成本等于对角线距离（每步对角线移动成本为 $\sqrt{2}$ ）。算法 1 给出了 JPS 搜索过程的伪代码。路径重建方面，JPS 搜索完成后，通过父节点指针从目标节点回溯至起点，并在相邻跳跃点之间沿直线插值补充被跳过的中间栅格，即可得到完整路径。然而，由于 JPS 的跳跃特性，重建路径中的对角线移动可能穿越障碍物拐角。为此，本文算法在路径重建阶段引入了对角拐点修正机制：当检测到对角线移动穿越障碍物拐角时，将其替换为沿栅格边界行走的 L 形路径（先走行再走列，或先走列再走行），从而避免与障碍物发生碰撞。修正后的路径严格沿栅格边界行进，保证了路径的可行性。此外，JPS 的剪枝规则依赖于均匀的栅格地图结构。在包含复杂障碍物分布的地图中，被迫邻居的产生频率增加，JPS 的优势会被削弱，个别情况下对称性假设失效可能导致 JPS 搜索失败。为此，本文提出的改进 A^* 算法在 JPS 搜索耗尽开放集仍未找到路径时，自动回退至传统 A^* 重新搜索，以确保在存在可行解时总能找到路径。这一降级机制保证了算法的鲁棒性，使其能够适应不同复杂度的环境。

2) **打破平局策略**：当开放集中的多个节点具有相同的 f 值时，标准 A^* 的选择顺序取决于具体实现（通常是先入先出或随机），本质上是任意的。然而，在 f 值相同的节点中， h 值较小的节点意味着其实际代价 $g = f - h$ 较大，即该节点距起点更远、更接近目标。优先扩展此类节点可将搜索方向导向目标，且不影响最优性保证。为此，本文提出的改进 A^* 算法采用“ f 值相同时优先选择 h 值更小的节点”的打破平局策略，二叉

Algorithm 1 JPS-based A* search

Require: occupancy grid map, start grid S , goal grid G

Ensure: grid path $P = [S, \dots, G]$, or failure

```

1: initialize  $g(S) = 0$ ,  $f(S) = h(S, G)$ , and insert  $S$ 
   into the open set (a binary min-heap);
2: while the open set is not empty do
3:    $n \leftarrow$  the node in the open set with the smallest
      $f$ -value, breaking ties by the smaller  $h$ ;
4:   if  $n = G$  then
5:     reconstruct and return the grid path  $P$ ;
6:   end if
7:   move  $n$  into the closed set, and record its parent
     direction  $\mathbf{d}_n$ ;
8:    $D \leftarrow$  the pruned successor directions of  $n$  deter-
     mined by  $\mathbf{d}_n$  (all eight directions if  $n = S$ );
9:   for each direction  $\mathbf{d} \in D$  do
10:     $s \leftarrow \text{Jump}(n, \mathbf{d})$ , the first jump point encoun-
      tered along  $\mathbf{d}$ , or null;
11:    if  $s = \text{null}$  or  $s$  is closed then
12:      continue;
13:    end if
14:     $\text{tent\_g} \leftarrow g(n) + \text{Cost}(n, s)$ , where straight
      steps cost 1 and diagonal steps cost  $\sqrt{2}$ ;
15:    if  $\text{tent\_g} < g(s)$  then
16:      set the parent of  $s$  to  $n$ ,  $g(s) \leftarrow \text{tent\_g}$ ,
       $f(s) \leftarrow \text{tent\_g} + h(s, G)$ ;
17:      insert  $s$  into the open set, or update its heap
      position if already present;
18:    end if
19:  end for
20: end while
21: if the open set is exhausted without reaching  $G$ 
   then
22:   fall back to standard A*;
23: end if

```

堆中的节点比较规则定义为:

$$\begin{cases} n_1, & f(n_1) < f(n_2) \\ n_2, & f(n_1) > f(n_2) \\ n_1, & f(n_1) = f(n_2) \wedge h(n_1) < h(n_2) \\ n_2, & f(n_1) = f(n_2) \wedge h(n_1) > h(n_2) \end{cases} \quad (10)$$

该比较规则直接嵌入二叉堆的上浮 (bubbleUp) 与下沉 (bubbleDown) 操作中。从物理意义上理解, 由评估函数 $f(n) = g(n) + h(n)$ 可知, 当两个节点的 f 值相同时, g 值较大者 h 值较小。 g 值较大表示该节点距起点更远, 而 h 值较小表示其更接近目标。优先扩展此类节点使搜索偏向目标方向, 减少了远离目标区域的无效探索。由于 h 值在节点扩展时已经计算, 此打破平局策略不产生额外计算开销。

B. 路径后处理

JPS 搜索得到的路径由栅格中心点序列组成, 存在两个主要问题: 路径包含冗余的中间点, 且由离散的水平 and 垂直段组成导致平滑性不足。本节提出一种两阶段后处理流水线来解决这些问题。

1) 安全感知路径简化: 传统的路径简化方法 (如拐角裁剪) 直接连接路径上的非相邻节点, 跳过中间点以减少路径点数量。然而, 这类方法通常仅检查连接线段是否穿越障碍物, 忽略了路径点与障碍物之间的安全裕度, 在障碍物密集区域可能导致路径过于贴近障碍物。为此, 本节提出一种安全距离感知的路径简化算法, 其核心思想是在简化过程中保持路径与障碍物之间的最小安全距离。该算法采用四步流程处理输入路径: 首先从路径中识别方向发生变化的节点 (即拐点)。对于路径中的每个中间节点, 计算其与前后节点的连接方向。若前向连接方向与后向连接方向不同, 则该节点标记为拐点。路径的起点和终点始终保留。其次从当前拐点 C_i 出发, 正向扫描所有后续拐点 C_j ($j > i$), 调用 ISLINEFREE 逐一验证线段 $C_i \rightarrow C_j$ 是否满足安全距离约束, 并记录最远的可达拐点 j^* 。该拐点成为新的锚点, 其间的所有拐点被跳过。这种贪心策略在保证安全性的前提下最大化了单步简化程度。在此基础上, 贪心步骤确定最远可达拐点 j^* 后, 算法检查被跳过的拐点 k ($i < k < j^*$) 能否通过安全线段直达更远处的拐点 j' ($j' > j^*$)。对每一对满足安全约束的 (k, j') , 算法计算并比较两条路径的代价。若存在这样的中间拐点, 则可能得到比纯贪心更短的简化路径。随后比较两条路径的长度: 路径 A (贪心) 为 $d(C_i, C_{j^*}) + d(C_{j^*}, C_{j'})$, 即先到达 j^* 再继续到 j' ; 路径 B (经中间点) 为 $d(C_i, C_k) + d(C_k, C_{j'})$, 即跳过 j^* 改经 k 路由。若路径 B 更短, 则保留中间拐点 C_k ; 否则仅保留贪心结果 C_{j^*} 。这一比较确保中间点探索不会以牺牲路径效率为代价。安全性检查函数

ISLINEFREE($p_1, p_2, \text{map}, d_{\text{safe}}$) 的实现基于逐栅格采样: 从 p_1 到 p_2 沿线段密集采样, 对每个采样点计算其与最近障碍物栅格边界的距离。只要任意采样点的距离小于安全阈值 d_{safe} , 即判定该连接不安全。点到栅格边界的距离计算公式为:

$$\begin{aligned} d_x &= \max(0, |p_r - c_r| - 0.5) \\ d_y &= \max(0, |p_c - c_c| - 0.5) \end{aligned} \quad (11)$$

$$d(p, \text{cell}) = \sqrt{d_x^2 + d_y^2} \quad (12)$$

其中, $p = (p_r, p_c)$ 为连续坐标下的采样点, $c = (c_r, c_c)$ 为障碍物栅格的中心坐标, 栅格占据矩形区域 $[c_r - 0.5, c_r + 0.5] \times [c_c - 0.5, c_c + 0.5]$ 。 $\max(0, \cdot)$ 算子处理采样点在某坐标轴上已落入栅格水平或垂直范围内的情况。当 $d(p, \text{cell}) < d_{\text{safe}}$ 时, 表示采样点已进入障碍物栅格的安全禁区。安全距离阈值 d_{safe} 取为机器人半径 r_{robot} 与附加安全裕度之和, 从而保证路径中心线到障碍物的间距不小于机器人半径, 避免碰撞 (默认配置见表 I)。算法 2 给出了路径简化算法的伪代码。安全性检查函数 ISLINEFREE 的伪代码如算法 3 所示。搜索半径 d_{max} 设置为 $[d_{\text{safe}} + 0.5]$, 因为超出此距离的栅格不可能与采样点的安全距离产生交集。

2) 弧长参数化三次样条平滑: 路径简化后的路径虽已去除冗余点, 但仍由直线段连接组成, 在拐点处存在曲率突变, 不适合全向机器人的平滑运动。本节采用三次样条插值对简化路径进行平滑处理。传统的三次样条插值直接以路径点的索引作为参数进行拟合, 当路径点间距不均匀时会导致曲线形状失真。为这一问题, 本节采用弧长参数化方法, 以路径点之间的累积欧氏距离作为参数, 使参数空间与实际几何空间保持一致。平滑过程分为三个步骤: 第一步是稀疏段致密化: 检测路径中相邻点间距超过 2 个栅格单位的线段。对于这些稀疏段, 在两端点之间沿线段线性插值 $\lfloor \ell/2 \rfloor$ 个中间点。致密化的目的是为样条曲线提供足够的控制点, 防止曲线在长直段处因控制点不足而产生的过冲 (Runge 现象), 避免曲线偏离预期折线甚至裁剪障碍物角点。第二步进行弧长参数化。设致密化后的路径点序列为 $\{P_0, P_1, \dots, P_M\}$, 其中 $P_i = (x_i, y_i)$ 为连续坐标。计算各点的累积弦长 (弧长) 参数:

$$s_0 = 0, \quad s_i = s_{i-1} + \|P_i - P_{i-1}\|_2, \quad i = 1, 2, \dots, M \quad (13)$$

然后分别以 s 为自变量对 $x(s)$ 和 $y(s)$ 进行三次样条插值, 得到参数化曲线 $(x(s), y(s))$ 。三次样条在每个子

Algorithm 2 Safety-distance-aware path simplification

Require: grid path $P = [P_1, \dots, P_N]$, occupancy grid, safety margin d_{safe}

Ensure: simplified path P_s ($|P_s| \leq N$)

```

1:  $C \leftarrow$  the corner points of  $P$  where the direction
   changes, plus the two endpoints;
2:  $P_s \leftarrow [C_1]$ ;  $i \leftarrow 1$ ;
3: while  $i < |C|$  do
4:    $j^* \leftarrow$  the farthest corner reachable from  $C_i$  by a
     collision-free segment; greedy forward scan
5:   if  $j^* = |C|$  then
6:     append  $C_{|C|}$  to  $P_s$  and break;
7:   end if
8:    $(k^*, j') \leftarrow$  among all skipped corners  $k$  ( $i < k < j^*$ ) and farther corners  $j$  ( $j^* < j \leq |C|$ ), the pair
     with the largest  $j$  such that the segment  $C_k \rightarrow C_j$ 
     is collision-free;
9:   if  $k^*$  exists and  $d(C_i, C_{k^*}) + d(C_{k^*}, C_{j'}) < d(C_i, C_{j^*}) + d(C_{j^*}, C_{j'})$  then
10:    append  $C_{k^*}$  and  $C_{j'}$  to  $P_s$ , and set  $i \leftarrow j'$ ;
     route through the intermediate corner
11:   else
12:    append  $C_{j^*}$  to  $P_s$ , and set  $i \leftarrow j^*$ ;
13:   end if
14: end while
15:
16: return  $P_s$ ;

```

区间 $[s_i, s_{i+1}]$ 上为三次多项式, 保证一阶和二阶导数连续, 从而确保曲线的曲率连续性。第三步进行等弧长重采样。以插值密度 ρ (每段等弧长插入的采样点数, 见表 I) 沿弧长参数 s 均匀采样, 生成最终的平滑路径点序列。由于 s 与实际几何距离近似线性关系, 等弧长采样保证了路径点在空间中的均匀分布, 避免了传统等参数采样在曲率大处点密、曲率小处点疏的问题。算法 4 给出了平滑算法的伪代码。

3) 流水线集成: 上述后处理操作以流水线方式集成: JPS 搜索 (算法 1) 输出原始栅格路径 $\rightarrow$ SimplifyPath (算法 2) 去除冗余点 $\rightarrow$ SmoothPath (算法 4) 生成平滑的连续坐标路径。整个流水线在 SimulationManager 中一次性完成, 输出的路径既满足

Algorithm 3 IsLineFree (collision check with safety margin)

Require: segment endpoints p_1, p_2 (grid coordinates), occupancy grid, safety margin d_{safe}

Ensure: true if the segment keeps distance $\geq d_{\text{safe}}$ from every obstacle, false otherwise

```

1:  $\ell \leftarrow \max(|p_1.r - p_2.r|, |p_1.c - p_2.c|)$ ;
2:  $N_s \leftarrow \max(\lceil 10 \cdot \ell \rceil, 30)$ ; number of dense sample points
3:  $d_{\text{max}} \leftarrow \lceil d_{\text{safe}} + 0.5 \rceil$ ; search radius in cells
4: for  $k = 0$  to  $N_s$  do
5:    $p \leftarrow p_1 + (k/N_s) \cdot (p_2 - p_1)$ ; sample point in continuous coordinates
6:   for each cell  $(r, c)$  within Chebyshev distance  $d_{\text{max}}$  of  $p$  do
7:     if  $(r, c)$  is occupied then
8:        $d \leftarrow$  the distance from  $p$  to the boundary of cell  $(r, c)$ ; see Eqs. (11)–(12)
9:       if  $d < d_{\text{safe}}$  then
10:
11:         return false;
12:       end if
13:     end if
14:   end for
15: end for
16:
17: return true;
```

安全性约束, 又具有良好的平滑性, 可直接用于机器人的运动跟踪。这种两阶段设计的合理性在于: 路径简化和样条平滑分别解决了路径质量的两个不同维度。简化减少了路径点数量 (降低了后续计算的复杂度), 同时通过安全距离约束保证了路径的安全裕度; 平滑则将离散的栅格路径转化为连续曲线, 使机器人能够以平滑的运动轨迹跟踪路径。若跳过简化直接进行平滑, 样条曲线需要处理大量冗余的控制点, 不仅计算成本更高, 还可能因控制点过于密集而产生不稳定的曲线形状。消融实验 (表 VI) 的结果也验证了这一设计的有效性。路径后处理前后对比如图 2 所示。

Algorithm 4 Arc-length parameterized cubic spline smoothing

Require: grid path $P = [P_1, \dots, P_N]$, density ρ (default 10)

Ensure: smoothed continuous path $Q = [Q_1, \dots, Q_M]$ in $[x, y]$

```

1: convert each grid point  $P_i = (r_i, c_i)$  to continuous coordinates  $(x_i, y_i) = (c_i - 0.5, r_i - 0.5)$ ;
2: for each consecutive pair whose segment length exceeds 2 do
3:   insert  $\lfloor \text{length}/2 \rfloor$  equally spaced intermediate points along the segment; densification to prevent spline overshoot
4: end for
5: compute the cumulative chord length  $t_1 = 0, t_i = t_{i-1} + \|P_i - P_{i-1}\|_2$ ; arc-length parameter
6: remove duplicate  $t$  values to keep strict monotonicity;
7: fit cubic splines  $x(t)$  and  $y(t)$  through the densified points;
8: sample  $x(t)$  and  $y(t)$  at  $\rho$  points per segment to obtain  $Q$ ;
9:
10: return  $Q$ ;
```




图 2. 路径通过管线各阶段的对比。

C. 改进的开放旅行商蚁群优化

本框架的第二层在全局规划层产生的代价矩阵上求解开放旅行商问题。给定由固定起点 S 、 K 个中间目标点 $\{T_1, \dots, T_K\}$ 和固定终点 G 组成的 N 个点, 目标是找到使总路径代价最小的 K 个目标点排列。我们在

蚁群优化 (ACO) 元启发式方法基础上引入六个集成机制: (1) 虚拟节点法, 将开放旅行商问题转化为标准闭环旅行商问题; (2) 最大-最小蚁群系统 (MMAS) 信息素管理及动态更新边界; (3) 蚁群系统 (ACS) 风格的伪随机比例转移规则, 平衡探索与利用; (4) 以 k 近邻候选列表加速的可变邻域下降 (VND) 局部搜索; (5) S 形渐进调度策略, 将搜索从探索主导逐渐转向利用主导; (6) 自适应停止准则。

1) 虚拟节点法编码开放旅行商问题: 在标准闭环旅行商问题中, 解为哈密顿回路, 任意城市均可作为起始点。在我们的问题中, 起点 S 和终点 G 是由任务规格确定的物理上不同的位置——例如无人公交的始发站和终点站。这两个点必须出现在每个候选解的固定位置 (首尾), 优化仅针对 K 个中间目标点的排序进行。将所有 N 个点对称排列的朴素编码会产生将起点/终点混入路径中间的无效路径; 而将起点/终点固定在路径两端的边界固定编码将其排除在信息素模型和局部搜索之外, 限制了算法对完整解的优化能力。为此, 本文采用虚拟节点 (哑节点) 法将开放旅行商问题转化为标准闭环旅行商问题, 该技术在开放车辆路径问题中被广泛采用 [31], [32]。引入虚拟节点 $V = N + 1$, 构造 $(N + 1) \times (N + 1)$ 的扩展代价矩阵 $\mathbf{D}_{\text{ext}}$:

$$\mathbf{D}_{\text{ext}}(i, j) = \begin{cases} 0, & \{i, j\} = \{V, 1\} \\ 0, & \{i, j\} = \{V, N\} \\ \text{BIG}, & (i = V \vee j = V) \wedge \{i, j\} \cap \{1, N\} = \emptyset \\ \mathbf{D}(i, j), & \text{otherwise} \end{cases} \quad (14)$$

其中 $\text{BIG} = 2(N + 1) \cdot \max_{i,j} \mathbf{D}(i, j)$ 为严格大于任何可行回路代价的惩罚值, 确保虚拟节点在任何近优回路中不直接连接任何中间目标点。虚拟节点与起点和终点之间的零代价边使虚拟节点对路径代价 “不可见”, 而与中间目标点之间的惩罚边强制虚拟节点仅与起点和终点相邻。蚁群优化求解器在扩展代价矩阵 $\mathbf{D}_{\text{ext}}$ 上作为标准闭环旅行商问题运行: 所有蚂蚁构建访问包括虚拟节点的 $N + 1$ 个节点并形成完整哈密顿回路, 信息素矩阵 τ 覆盖完整的 $(N + 1) \times (N + 1)$ 空间。求解器收敛后, 通过以下步骤从最优回路中提取开放路径访问顺序:

- 1) 定位回路中的虚拟节点 V 。
- 2) 移除 V 并按回路顺序读取剩余 N 个节点。
- 3) 调整方向使起点出现在首位、终点出现在末位。

该转换相对边界固定编码有三个优势: (a) 起点和终点节点完整参与信息素模型和局部搜索, 而非被排除为固定边界; (b) 所有标准闭环旅行商算子统一适用, 无需特殊边界处理; (c) 代价评估为 $\mathbf{D}_{\text{ext}}$ 上的简单回路求和, 避免了单独边界代价项的需求。启发式可见度矩阵 η 在扩展空间上定义。对涉及虚拟节点的点对, 虚拟节点到起点或终点的零代价边赋予大启发式值 BIG, 强烈吸引虚拟节点连接其所需邻居。对其他点对:

$$\eta_{ij} = \begin{cases} \frac{1}{\mathbf{D}_{\text{ext}}(i, j)}, & \mathbf{D}_{\text{ext}}(i, j) \in (0, +\infty) \\ 0, & \text{otherwise} \end{cases} \quad (15)$$

闭合回路 $\sigma = (\sigma_1, \sigma_2, \dots, \sigma_{N+1})$ 的代价为:

$$C(\sigma) = \sum_{k=1}^N \mathbf{D}_{\text{ext}}(\sigma_k, \sigma_{k+1}) + \mathbf{D}_{\text{ext}}(\sigma_{N+1}, \sigma_1) \quad (16)$$

2) 具有动态边界的最大-最小蚁群系统信息素更新: 在基本蚁群系统中, 所有蚂蚁在其完整路径上沉积信息素, 当少数蚂蚁偶然找到中等质量的路径时可能导致搜索过早集中于次优解。反之, 无边界的过度蒸发可能使信息素值在除主导边之外的所有边上趋近于零, 将种群困在局部最优。最大-最小蚁群系统 (MMAS) [23] 通过以下方式解决这两个问题: (a) 将信息素限制在显式区间 $[\tau_{\min}, \tau_{\max}]$ 内, 防止支配和灭绝; (b) 聚焦于最优性能解的沉积。据此, 每次迭代时所有信息素值首先进行蒸发:

$$\tau_{ij} \leftarrow (1 - \rho) \cdot \tau_{ij} \quad \forall i, j \in \{1, \dots, N + 1\} \quad (17)$$

其中 ρ 为蒸发率。蒸发后, 在两个解层次的边上沉积信息素: 蒸发之后, 当代最优蚂蚁在其回路的所有边上沉积信息素:

$$\tau_{ij} \leftarrow \tau_{ij} + \frac{Q}{C_{\text{iter}}} \quad \forall (i, j) \in \text{edges}(\sigma_{\text{iter-best}}) \quad (18)$$

同时, 搜索开始以来找到的最优回路也获得沉积, 以强化全局主导解:

$$\tau_{ij} \leftarrow \tau_{ij} + \frac{Q}{C_{\text{global}}} \quad \forall (i, j) \in \text{edges}(\sigma_{\text{global-best}}) \quad (19)$$

其中 Q 为沉积常数, C 为回路代价。沉积量与回路代价成反比, 因此更短 (更优) 的回路沉积更强的信息素。两个沉积级别同时应用于对称对 (j, i) , 保持无向信息

素模型。沉积后,所有信息素值被限幅到 $[\tau_{\min}, \tau_{\max}]$ 区间,其边界根据当前全局最优动态更新:

$$\tau_{\max} = \frac{1}{\rho \cdot C_{\text{global}}} \quad (20)$$

$$\tau_{\min} = \frac{\tau_{\max}}{N+1} = \frac{1}{\rho \cdot (N+1) \cdot C_{\text{global}}} \quad (21)$$

并设有硬下限 $\tau_{\min}$ 以防止低频边上信息素完全灭绝。边界的动态更新至关重要:随着搜索发现更优回路 (C_{global} 减小), $\tau_{\max}$ 增大,允许算法对其当前最优解表达更强的置信。反之,比率 $\tau_{\min}/\tau_{\max} = 1/(N+1)$ 维持最小与最大信息素之间的恒定相对间隔,无论绝对尺度如何,都为所有边保持基线探索概率。初始信息素矩阵设为均匀值 τ_0 ,表示搜索经验积累前的中性先验。

3) 蚁群系统风格的伪随机转移规则:在标准蚁群系统中,每只蚂蚁通过纯概率轮盘选择从未访问的候选集中选择下一节点。此方法探索性强,在距离启发式提供可靠引导的结构化问题上收敛缓慢。蚁群系统 (ACS) [22] 通过伪随机比例规则解决此问题:用可控概率使蚂蚁贪心地选择最优候选;否则通过标准概率机制探索。这平衡了收敛需求 (利用) 与避免局部最优的需求 (探索)。具体实现时,当蚂蚁在当前节点 u 从未访问候选集 $\mathcal{U}$ 中选择下一节点时,首先计算每个候选的得分:

$$\text{score}(v) = (\tau_{uv})^\alpha \cdot (\eta_{uv})^\beta \quad \forall v \in \mathcal{U} \quad (22)$$

其中 α 和 β 分别为信息素和启发式权重指数。转移决策遵循:

$$v_{\text{next}} = \begin{cases} \arg \max_{v \in \mathcal{U}} \text{score}(v), & \text{概率 } q_0 \\ \text{roulette}(\mathcal{U}, \text{score}), & \text{概率 } 1 - q_0 \end{cases} \quad (23)$$

其中 q_0 为利用概率。在利用情形中,蚂蚁确定性地选择得分最高的候选——等价于贪心最优步。在探索情形中,蚂蚁执行轮盘选择,每个候选 v 以 $\text{score}(v)/\sum_{u \in \mathcal{U}} \text{score}(u)$ 的概率被选中。若所有得分为零即所有剩余节点不可达,则随机选择一个未访问候选作为回退。可以看出, q_0 越大,越多的构建步采用贪心选择以加速收敛; q_0 越小,则随机探索的比重越高。障碍约束代价矩阵中的点对距离通常具有空间局部性,因而启发式 η 能够提供较可靠的引导,这使得中等偏上的贪心概率在保证多样性的前提下仍有利于收敛 (默认取值见表 I)。

4) 具有候选列表加速的可变邻域下降局部搜索:蚂蚁所构建的路径虽受信息素与启发式信息引导,但

仍未必达到局部最优。一个自然的改进思路是:在每一代对当前最优解施加局部搜索,通过系统考察邻域排列来进一步精化解的质量。可变邻域下降 (Variable Neighborhood Descent, VND) [24] 正是这样一类方法,它依次调用多种邻域结构,每种结构对应一类路径变换,并在当前结构无法继续改进时切换到下一种,直至所有邻域均无法产生更优解。已有研究表明,将 MMAS 或 ACS 与 VND 混合在车辆路径问题中效果显著 [25]。不过,标准 VND 在每个算子上需考察 $O(K^2)$ 个邻域,当目标点规模增大时计算开销会迅速上升,成为主要瓶颈。进一步观察可以发现,这类考察中大量尝试并不奏效:相距较远的节点对参与 2-opt 交换时,往往很难带来回路代价的改善。

针对上述问题,本文在包含虚拟节点在内的 $N+1$ 个节点所构成的闭合回路上实施 VND,并按固定顺序交替使用三种邻域算子。各算子的作用及配套的候选列表剪枝条件如下:

- 1) **2-opt**: 将路径中一段连续子序列整体反转,即用边 (u, v) 与 (u^+, v^+) 替换原边 (u, u^+) 与 (v, v^+) ,从而消除欧氏型代价下常见的路径交叉。评估该翻转前,仅当新边 (u, v) 与 (u^+, v^+) 中至少有一对属于候选近邻时,才计算代价变化。
- 2) **重定位**: 从当前位置取出某一节点,将其插入回路的其他位置,并相应平移中间节点,用于纠正节点被错误放置到不同路径区段的情形。评估该插入前,仅当被移动节点 v 与其新邻居之一 (p 或 p^+) 互为候选近邻时,才继续考察。
- 3) **交换**: 在保持其余节点不变的前提下对调两个节点的位置,适用于两节点恰被安排到对方更优位置的情况。评估该对调前,仅当待交换的两个节点 a 与 b 互为候选近邻时,才考虑执行。

上述算子在 VND 循环中采用“首次改进” (first-improvement) 策略:先反复进行 2-opt,直至无法再降低代价;若仍无改进则转为重定位,最后尝试交换。只要任一算子产生改进,便重新从 2-opt 开始新一轮循环;当三种算子均无法进一步改进时,局部搜索终止。

在计算效率方面,本文引入预计算的候选列表,以过滤上述各类评估中明显缺乏前景的情形,这一思路在旅行商问题的局部搜索中已有广泛应用 [26]。具体而言,对扩展问题中的每一个节点 (共 $N+1$ 个),根据扩展代价矩阵 $\mathbf{D}_{\text{ext}}$ 预先筛选其 k 个最近邻,并以布尔矩阵 $\mathbf{C}$ 加以存储,其中 $\mathbf{C}(i, j) = \text{true}$ 表示节点 j 属于节点

i 的候选近邻；上文各算子中所提到的“候选近邻”均指该列表中的节点。需要说明的是，上述剪枝在设计上偏于保守：只有当移动所涉及的新边均不在候选近邻集合中时，才跳过评估。这种情形通常意味着该移动难以改善回路，但并不能视为绝对保证。候选列表规模 k 宜取得较小（默认取值见表 I），既可过滤掉大量无效计算，又保留最有可能带来改进的局部结构；当扩展代价矩阵呈现较强的空间聚集特性时，改进边交换几乎只可能发生在邻近节点之间，因此该设置尤为有效。

从复杂度来看，若不采用剪枝，每个 VND 算子需考察 $O((N+1)^2)$ 个候选移动；引入候选列表后，每个节点仅需参与约 $O(k)$ 次邻域检查，单算子复杂度降为 $O((N+1) \cdot k)$ 。当 k 取个位数量级时，相对全邻域考察约可降低一个数量级的计算量；随着 N 增大，加速效果会更加明显。

算法 5 给出了候选列表加速 VND 的完整伪代码。需要补充的是，上述三个邻域算子均按首次改进原则运行，即一旦发现能够降低回路代价的移动便立即接受并返回；由于问题定义在闭合回路上，当交换操作跨越回路的首尾相邻节点时，还需额外考虑环绕邻接关系，而不能简单沿用线性路径下的邻接判断。VND 邻域搜索的完整流程如图 3 所示。如前所述，三个邻域算子均按首次改进原则运行，即一旦发现能够降低回路代价的移动便立即接受并返回；由于问题定义在闭合回路上，当交换操作跨越回路的首尾相邻节点时，还需额外考虑环绕邻接关系，而不能简单沿用线性路径下的邻接判断。VND 邻域搜索的完整流程如图 3 所示。

5) S 形渐进局部搜索调度：即使引入了候选列表加速，VND 局部搜索仍需要可观的计算时间。若在每一代对所有蚂蚁都做局部搜索，早期迭代的资源往往会被浪费：此时种群尚未辨明搜索空间中较有希望的区域，精化低质量路径的收益有限。相反，到了后期，当信息素已集中于高质量区域时，密集局部搜索对于进一步打磨解却十分关键。可见，若始终对固定比例的蚂蚁实施局部搜索并不理想——比例偏低会减慢收敛，偏高则在尚未成熟的解上耗费算力。为此，本文在迭代过程中按 S 形（sigmoid）函数动态调整接受 VND 局部搜索的蚂蚁比例：

$$\text{optRatio}(t) = y_{\min} + (y_{\max} - y_{\min}) \cdot \frac{t^a}{t^a + (1-t)^a} \quad (24)$$

式中， $t = (\text{iter} - x_L)/(x_R - x_L)$ 为当前迭代在转换区间 $[x_L, x_R]$ 内的归一化位置； $y_{\min}$ 与 $y_{\max}$ 分别表示搜

Algorithm 5 Candidate-list-accelerated variable neighborhood descent

Require: closed tour $\sigma = [\sigma_1, \dots, \sigma_{N+1}]$, extended cost matrix $\mathbf{D}_{\text{ext}}$, candidate boolean matrix $\mathbf{C}$

Ensure: improved tour σ and its cost

- 1: cost $\leftarrow$ the cost of tour σ under $\mathbf{D}_{\text{ext}}$;
- 2: **repeat**
- 3: improved $\leftarrow$ false;
- 4: $[\sigma, \text{cost}, \text{ok}] \leftarrow$ apply the 2-opt operator with candidate-list pruning (first-improvement);
- 5: improved $\leftarrow$ improved or ok;
- 6: $[\sigma, \text{cost}, \text{ok}] \leftarrow$ apply the relocate operator with candidate-list pruning;
- 7: improved $\leftarrow$ improved or ok;
- 8: $[\sigma, \text{cost}, \text{ok}] \leftarrow$ apply the swap operator with candidate-list pruning;
- 9: improved $\leftarrow$ improved or ok;
- 10: **until** improved = false
- 11: cost $\leftarrow$ the exact cost of the final tour σ ;
- 12:
- 13: **return** σ , cost;




图 3. VND 邻域搜索序列流程图。

索初期与后期接受局部搜索的蚂蚁比例上下限， a 用于控制 S 形曲线的陡峭程度（默认取值见表 I）。当 t 位于 x_L 之前时， optRatio 取 $y_{\min}$ ；超过 x_R 之后则保持为 $y_{\max}$ ；在区间内部，比例沿 S 形曲线平滑过渡。

这一调度方式使搜索过程自然形成三个阶段。早期 $\text{optRatio} \approx y_{\min}$ ，种群主要依赖路径构建阶段的随机性来广泛探索，而不必承担局部搜索开销；在过渡阶段，

接受优化的蚂蚁逐步增多,使信息素能够吸收由局部搜索得到的改进解;后期 optRatio 稳定在 $y_{\max}$,在继续由部分蚂蚁维持构建多样性的同时,以足够多的算力精化当前优质解。转换区间之所以取得较短的 $[0, 30]$,是为了让比例尽早达到上限:实验表明,基本信息素结构往往在约 30 代内形成,此后加密局部搜索即可获得明显收益。S 形 $\text{optRatio}(t)$ 曲线如图 4 所示。在确定本轮接受局部搜索的蚂蚁数目 $n_{\text{opt}} = \lceil n_{\text{ants}} \cdot \text{optRatio} \rceil$ 之后,还需从中挑选具体个体。本文采用精英与随机相结合的方式:

$$n_{\text{elite}} = \lceil n_{\text{opt}} \cdot r_{\text{elite}} \rceil \quad (25)$$

$$n_{\text{random}} = n_{\text{opt}} - n_{\text{elite}} \quad (26)$$

其中 r_{elite} 为精英占比参数(见表 I),即优先把较多的局部搜索预算用于当前排名靠前的蚂蚁,以强化对优质解的精细打磨;其余 n_{random} 只蚂蚁则从非精英个体中随机抽取并同样接受优化,从而有机会发现精英之外的其他有潜力区域,在利用与探索之间保持平衡。

6) 自适应停止准则:算法将最大迭代次数 n_{iter} 作为迭代预算上限(默认取值见表 I),以免在困难实例上因预算不足而无法收敛。但在较易实例中,种群往往远在此之前就已收敛,继续迭代只会增加计算开销,而难以带来解质量的提升。反过来,若过早停止,又可能错过更优解。因此,停止准则需要在“已充分收敛”与“暂时尚未改进”之间加以区分,既识别真正的收敛,也避免因短暂停滞而误停。

具体而言,算法同时监测两个互补的指标。

第一个指标是种群同质性。当蚁群收敛到搜索空间中某个较窄的区域时,不同蚂蚁给出的回路代价会彼此接近,方差随之变小。本文用每代蚂蚁回路代价的变异系数(coefficient of variation, CV)对此加以刻画:

$$\text{CV} = \frac{\sigma_{\text{costs}}}{\mu_{\text{costs}}} \quad (27)$$

其中 σ_{costs} 与 μ_{costs} 分别为当代全部蚂蚁回路代价的标准差与均值。当 CV 低于预设阈值 ε_{CV} (见表 I)时,可认为种群已趋于同质,即各回路质量大体相当,继续搜索发现新解的可能性已经很低。

第二个指标是最优解是否陷入停滞。即使种群内部仍有一定多样性,当前全局最优回路也可能长时间停留在某个局部最优附近。为此,算法记录全局最优代价连续未获改进的迭代次数,一旦达到预设上限 $\text{stagn}_{\max}$ (见表 I),便终止搜索。




图 4. S 形 $\text{optRatio}(t)$ 关于迭代次数的曲线图。

为减少误停风险,上述两个判据仅在完成最少迭代次数 minIter (见表 I)之后才启用。这是因为在搜索初期,代价方差通常较大、全局最优仍在快速改善,此时若立即监测收敛,容易把正常波动误判为已收敛;经过一段最低限度的搜索后,信息素结构已相对成形,此时给出的停止判断才更为可靠。

7) 集成总结:综合上述设计,MMAS-VND-CL 算法把六个机制组织进同一条迭代搜索流程:扩展代价矩阵 $\mathbf{D}_{\text{ext}}$ 定义在含虚拟节点的 $N+1$ 个节点上,信息素模型与局部搜索均在该空间中进行。单次迭代的主要步骤如下:

- 1) 由 S 形曲线(式 (24))确定本轮接受局部搜索的蚂蚁比例;
- 2) 全部蚂蚁按照 ACS 风格的伪随机转移规则(式 (22)–(23))各自构造一条覆盖 $N+1$ 个节点的哈密顿回路;
- 3) 依据精英—随机混合策略(式 (25)–(26))选出部分蚂蚁,对其回路执行带候选列表加速的 VND 局部搜索(算法 5);
- 4) 更新当前全局最优回路,并依据自适应停止准则(式 (27))判断是否终止;
- 5) 若继续搜索,则先按式 (17)蒸发信息素,再在本轮最优回路与全局最优回路上沉积(式 (18)–(19)),最后按 MMAS 规则对信息素取值进行动态限幅(式 (20)–(21))。

搜索在满足任一停止条件时结束,即种群代价的变异系数低于 ε_{CV} ,或全局最优回路连续 $\text{stagn}_{\max}$ 代没有改进;为避免误停,这些条件在 minIter 之前不参与判定。终止后,从最优回路中去掉虚拟节点 V ,再把剩余节点调整为起点在前、终点在后的顺序,便得到最终的开放路径访问序列。MMAS-VND-CL 算法的总体流程如图 5 所示。




图 5. 改进蚁群优化总体流程图。

D. 协同优化框架

前述各节分别介绍了两个算法层：负责点对点寻径的改进 A* 规划器及其后处理（第 IV-A-IV-B 节），以及面向开放旅行商问题的 MMAS-VND-CL 求解器（第 IV-C 节）。本节说明如何将二者衔接为一个完整的多目标点遍历框架。

1) 两层架构：该框架在结构上分为两层，从而把几何层面的避障寻径与组合层面的访问顺序优化清晰地分开。

第一层完成代价矩阵的构建。给定 N 个点（含一个起点、 K 个中间目标点和一个终点），对每一对点计算最短无碰撞路径，由此得到成对代价矩阵 $\mathbf{D} \in \mathbb{R}^{N \times N}$ ：

$$\mathbf{D}(i, j) = L(A^*(p_i, p_j, \mathbf{M})) \quad \forall i \neq j \in \{1, \dots, N\} \quad (28)$$

其中 $L(\cdot)$ 为路径长度函数， $\mathbf{M}$ 为占用栅格地图，对角元素取零。需要强调的是， $\mathbf{D}$ 并非欧氏距离矩阵：它的每一个元素都对应真实的障碍约束最短路径长度。当障碍物截断两点之间的直线通道时，该长度可能明显大于两点间的直线距离。

若启用 `enableSimplify` 选项，则路径长度 $L(\cdot)$

依据简化后的折线而非原始栅格路径来计算：

$$\mathbf{D}_{\text{simplified}}(i, j) = L_{\text{Euclidean}}(\text{SIMPLIFYPATH}(A^*(p_i, p_j, \mathbf{M}), \mathbf{M}, d_{\text{safe}})) \quad (29)$$

这里 $L_{\text{Euclidean}}$ 表示简化折线的欧氏长度。与栅格上的曼哈顿加对角线度量相比，它更接近机器人实际行走的连续距离。构建完整代价矩阵共需调用 $O(N^2)$ 次全局规划器；工程上还可选用以起止坐标对为键的路径缓存，保存已经算过的点对结果，从而避免在多次旅行商求解中重复进行 A* 搜索。

第二层完成访问顺序的优化。将代价矩阵 $\mathbf{D}$ 交给 MMAS-VND-CL 求解器（第 IV-C 节）即可。该层只在数值矩阵上操作，并不感知地图、障碍物或路径几何；全部约束信息都已压缩在 $\mathbf{D}$ 之中。求解器返回最优访问顺序 $\pi^* = (1, \pi_2, \dots, \pi_{K+1}, N)$ 及对应总代价 $C(\pi^*)$ 。

2) 管线集成：完整管线可分为如下四个阶段。

点集组装。将 $N = K + 2$ 个点写入统一的坐标数组 $\mathbf{P} = [p_{\text{start}}; \mathbf{T}_1; \dots; \mathbf{T}_K; p_{\text{goal}}]$ ，并约定索引 1 为起点、索引 N 为终点。

代价矩阵构建。对每一对有序点 (i, j) ($i \neq j$)，由全局规划器求出从 $\mathbf{P}(i, :)$ 到 $\mathbf{P}(j, :)$ 的最短无碰撞路径，写入路径缓存，并按所选代价模式将路径长度记入 $\mathbf{D}(i, j)$ ：

- 若启用 `enableSimplify`，则先对路径进行简化（第 IV-B 节），再按式 (29) 取欧氏长度，所得代价更接近真实连续行程；
- 若不启用简化，则直接采用原始栅格路径在曼哈顿加对角线度量下的长度（式 (28)）。

若某对点之间不存在可行路径，则相应元素记为 $\mathbf{D}(i, j) = \infty$ 。一旦有目标点从起点不可达，流程立即中止并报告失败。

旅行商求解。将 $\mathbf{D}$ 与点数 N 交给 MMAS-VND-CL，得到最优访问顺序 $\text{bestOrder} = (1, \dots, N)$ 及其总代价。当 $K = 0$ （无中间目标）时，问题退化为平凡情形：顺序为 $[1, N]$ ，代价即 $\mathbf{D}(1, N)$ 。

输出组装。按 bestOrder 从坐标数组中取出有序点列 $\mathbf{P}(\text{bestOrder}, :)$ ，并在路径缓存中查回相邻点对之间的各段路径，拼成最终的无障碍参考路径集，供后续平滑与机器人执行使用。

3) 设计原理：将两层分开设计，主要有三方面优点。

首先，规划器与旅行商求解器可以独立开发、测试与改进。第一层可换成任意栅格规划器（A*、Dijkstra、

RRT 等), 第二层也可换成任意排列优化算法(蚁群优化、遗传算法、模拟退火等)。这种模块化设计在第 V-C-V-E 节的实验中得到检验: 对比某一层的替代实现时, 另一层保持不变。

其次, 代价矩阵 $\mathbf{D}$ 充当了紧凑的接口。无论环境复杂程度如何, $N \times N$ 矩阵都完整记录了各点对之间的障碍约束距离关系。旅行商求解器因此无需接触栅格地图, 却仍具备避障意义上的可行性保证。当然, 这种压缩也有信息损失: 求解器无法判断两段路径是否共用同一条狭窄走廊。但就“最小化总代价”这一目标而言, 该表示是充分的。

再次, `enableSimplify` 选项体现了代价精度与计算开销之间的权衡。关闭该选项时, 代价按原始栅格路径在栅格度量下统计(正交步代价为 1, 对角步为 $\sqrt{2}$), 由于阶梯效应, 往往会高估连续路径的真实长度; 开启该选项后, 路径先经简化去掉锯齿状航点(第 IV-B 节), 再以折线欧氏长度计价, 得到的代价矩阵更接近物理行程, 代价是每一对点都需要额外调用一次 `SIMPLIFYPATH`。

4) 完整系统流程: 端到端运行时, 系统依次完成以下步骤:

- 1) **构建代价矩阵:** 对全部 $O(N^2)$ 个点调用改进 A* 规划器, 并可选地在计价前对路径作安全简化;
- 2) **求解开放旅行商问题:** 调用 MMAS-VND-CL 确定最优访问顺序;
- 3) **回取各段路径:** 依据访问顺序从路径缓存中拼接完整轨迹;
- 4) **后处理:** 对每段路径实施路径简化与三次样条平滑(第 IV-B 节), 输出可供机器人跟踪的平滑无障碍连续轨迹。

系统整体架构如图 6 所示。

V. 实验

在阐明所提框架的原理与机制之后, 本节通过一组仿真验证其有效性。为从不同维度评估算法性能, 设置四组实验: (1) 改进的 A* 全局规划器(基于 JPS)与基线规划器的性能对比; (2) 改进蚁群优化求解器的参数敏感性分析; (3) 隔离蚁群优化各组件贡献的消融实验; (4) 不同旅行商求解器与改进 A* 规划器协同完成多目标点遍历的对比实验。所有对比均在统一参数策略与多次独立运行下进行, 以兼顾结果质量与统计可靠性。




图 6. 系统架构总图

A. 实验设置

所有实验在配备 Intel Core Ultra 5 125H 处理器和 16 GB 内存的计算机上进行, 运行 MATLAB R2025b。

在测试地图方面, 两张栅格地图 (Map 1 和 Map 2) 为所有实验共用。第三张地图在两组实验之间不同: 全局路径规划对比(第 V-B 节)使用 80×80 迷宫栅格地图, 而旅行商实验(第 V-C-V-E 节)使用 kroB100 TSPLIB 基准数据集。

- **Map 1 (Map1.mat):** 一个中等障碍密度的栅格地图, 用于测试基本搜索性能(所有实验共用)。
- **Map 2 (Map2_kong.mat):** 一个更大的栅格地图, 具有开阔、走廊式的结构, 考验长距离直线遍历, 并在栅格路径中产生显著的阶梯伪影(所有实验共用)。
- **Map 3 (迷宫 x80_3.mat):** 一个 80×80 迷宫栅格地图, 仅用于全局路径规划对比(第 V-B 节)。
- **kroB100 (kroB100_coords.mat):** 一个标准的 100 城市 TSPLIB 基准实例, 仅用于旅行商排序实验(第 V-C-V-E 节)。

关于重复次数与统计, 全局路径规划对比(第 V-B 节)中, 每个算法在每张地图上运行 10 次, 时间指标取平均。旅行商实验(第 V-C-V-E 节)中, 每个算法配置在每张地图上运行 40 次, 统计指标(最优值、中位数、均值、标准差、成功率和代价极差)基于 40 次独立运行计算。

参数设置方面, 除非在敏感性分析(第 V-C 节)或消融实验(第 V-D 节)中另有说明, 全文使用表 I 中的默认参数值。

评估指标包括: 路径长度(栅格单位)、计算时间(秒)、扩展节点数(仅限全局规划)、最优/中位/平均收敛代价、成功率(达到最优代价的运行百分比)和标准差。

表 I
所提算法的默认参数设置

模块	参数	值
改进 A* (JPS)	回退规划器	传统 A*
A* (JPS)	启发式	标准欧氏距离
路径简化	安全距离 d_{safe}	0.4
路径平滑	插值密度 ρ	10
蚁群优化	蚂蚁数量 n_{ants}	40
蚁群优化	信息素权重 α	1
蚁群优化	启发式权重 β	2.0
蚁群优化	蒸发率 ρ	0.25
蚁群优化	沉积常数 Q	225
蚁群优化	初始信息素 τ_0	0.1
蚁群优化	贪心概率 q_0	0.45
蚁群优化	局部搜索比例 y_{max}	0.4
蚁群优化	局部搜索转换区间 $[x_L, x_R]$	$[0, 30]$
蚁群优化	精英比率 r_{elite}	0.7
蚁群优化	候选列表大小 k	9
蚁群优化	局部搜索比例下限 y_{min}	0.0
蚁群优化	S 形陡度 a	2.0
蚁群优化	同质性阈值 ε_{CV}	10^{-3}
蚁群优化	停滞上限 $\text{stagn}_{\text{max}}$	70
蚁群优化	最少迭代 minIter	30
蚁群优化	最大迭代 n_{iter}	800
路径简化	机器人半径 r_{robot}	0.2
路径简化	附加安全裕度	0.2

B. 全局路径规划对比

本组实验旨在对比所提基于 JPS 的改进 A* 规划器（含路径简化与平滑后处理）与三个基线规划器的搜索效率和路径质量：传统 A*、Dijkstra 和 RRT。实验流程如下：每个规划器在三张栅格地图（Map 1、Map 2 和 Map 3，即 80×80 迷宫）上运行。对于所提方法，报告结果包含完整处理后管线（SimplifyPath + SmoothPath）。每个算法在每张地图上运行 10 次，计算时间取平均。实验结果见表 II，其中汇总了每个算法在每张地图上的路径长度、计算时间和扩展节点数。RRT 是基于采样的方法，因此不报告扩展节点数。路径规划可视化结果见图 7。从结果来看，所提基于 JPS 的规划器在所有三张地图上均取得最短路径长度（Map 1 上 72.93 对比传统 A* 与 Dijkstra 的 76.53；Map 2 上 108.17 对比 111.44；Map 3 上 113.33 对比 119.64）。此路径长度优势源于简化阶段，其去除了阶梯伪影并有效缩短路径。在搜索效率方面，JPS 规划器比基线方法扩展更少的节点：Map 3 上仅扩展 48 个节点，对比传统 A* 的 280 个和 Dijkstra 的 566 个，减少超过 80%。这直接转化为更快的计算速度：Map 2 上所提方法以 11.85 ms 完成，对比传统 A* 的 29.19 ms 和 Dijkstra

表 II
全局路径规划性能对比

算法	地图	路径长度	时间 (ms)	扩展节点数
本文改进 A*	Map 1	72.93	2.45	70
	Map 2	108.17	11.85	415
	Map 3	113.33	4.31	48
A*	Map 1	76.53	6.14	81
	Map 2	111.44	29.19	198
	Map 3	119.64	17.88	280
Dijkstra	Map 1	76.53	24.26	200
	Map 2	111.44	202.29	522
	Map 3	119.64	204.46	566
RRT	Map 1	100.80	7.42	—
	Map 2	135.40	19.33	—
	Map 3	144.07	3.69	—

的 202.29 ms——比 Dijkstra 快 17 倍以上。RRT 产生最长路径（Map 1 上 100.80、Map 2 上 135.40、Map 3 上 144.07），方差较高，与其基于采样的性质一致。上述优势可归因于以下机制：JPS 通过对称性剪枝大幅减少冗余节点扩展，安全感知简化去除了栅格阶梯伪影并压缩航点数量，样条平滑则进一步将离散路径转化为可执行的连续曲线。三者叠加，使所提方法在保持可行性的同时获得了更短的路径与更高的计算效率。路径可视化对比如图 7 所示，路径长度与计算时间对比分别如图 8 和图 9 所示。

C. 参数敏感性分析

本组实验旨在分析本文所提 MMAS-VND-CL 求解器对五个关键超参数的敏感性：蚂蚁数量 n_{ants} 、贪心选择概率 q_0 、后期局部搜索比例 y_{max} （optRatio_end）、精英比率 r_{elite} （optEliteRatio）和候选列表大小 k （kCand）。实验中每个参数在五个水平上变化，同时其他参数保持默认值。每个参数的五个水平汇总于表 III。每个配置在每张地图上运行 40 次。完整敏感性结果见表 IV，覆盖（25 种配置 $\times$ 3 张地图）。参数水平依次为 $n_{\text{ants}}/q_0/y_{\text{max}}/r_{\text{elite}}/k$ 。

上述结果揭示了若干重要的敏感性特征。首先，蚂蚁数量 n_{ants} 具有中等影响：在 $n_{\text{ants}} = 40$ （默认值）时，算法在 Map 2 上达到 100% 成功率、kroB100 上达 97.5%，而减至 10 只蚂蚁使 kroB100 成功率降至 92.5% 并增加平均代价。其次，贪心概率 q_0 在默认值 0.45 处呈现明确最优：增至 0.9（近纯贪心）导致严重退化，kroB100 成功率降至 50%、标准差增至 42.06，表




图 7. 四种算法在三张地图上的路径规划结果。




图 8. 四个算法在 Map 1、2、3 上的路径长度对比（折线图）。




图 9. 四个算法在 Map 1、2、3 上的计算时间对比（折线图）。

表 III
敏感性分析中使用的参数水平

参数	参数水平				
	水平 1	水平 2	水平 3	水平 4	水平 5
n_{ants}	10	20	40	60	90
q_0	0.10	0.30	0.45	0.60	0.90
y_{max}	0.10	0.20	0.40	0.60	0.90
r_{elite}	0.1	0.3	0.5	0.7	0.9
k	3	9	15	30	60

明过早收敛。第三，后期局部搜索比例 y_{max} 至关重要：

减至 0.10 使 Map 2 成功率降至 65%、kroB100 降至 80%，证实密集后期局部搜索对解质量不可或缺。第四，精英比率 r_{elite} 和候选列表大小 k 的敏感性相对温和，候选列表大小 k 是最不敏感的参数——但过小的 $k = 3$ 使 kroB100 成功率降至 30%，表明最小候选列表对有效 VND 剪枝是必要的。这表明默认配置在收敛质量、稳定性与运行时间之间取得了良好折中，故后续实验均采用该组参数。各参数水平的代价与计算时间对比如图 10所示，默认参数下规划路径如图 11所示。

D. 蚁群优化组件消融实验

消融实验通过系统地逐个禁用各组件，隔离改进蚁群优化求解器中每个机制的独立贡献。

具体设置为：测试六个实验组，每组禁用一个机制，同时保持其他设置不变。表 V汇总了消融组。

所有地图上的完整消融结果见表 VI。消融过程可视化见图 12-14。

消融结果揭示了组件重要性的清晰层次。最关键的组件是 VND 局部搜索（组 3）：禁用后 kroB100 成功率崩溃至 0%，平均代价从 22142.45 增至 22566.98（退化 1.9%），标准差膨胀至 239.41。这证实 VND 对逃脱局部最优和实现近优解不可或缺。第二关键的组件是 MMAS 信息素边界（组 6）：移除后 Map 1 成功率降至 30%、Map 2 降至 10%，代价方差显著，证明信息素边界控制对防止过早收敛至关重要。伪随机转移规则（组 2）和 S 曲线调度（组 4）的影响更温和：移除伪随机规则实际上维持了 100% 成功率（以稍长运行时间为代价），而移除 S 曲线使 kroB100 性能轻微退化（成功率从 97.5% 降至 90%）。候选列表加速（组 5）对解质量的

表 IV
代表性参数敏感性结果

取值等级	地图	最优代价	平均收敛代价	成功率 (%)	平均时间 (ms)	标准差	取值等级	地图	最优代价	平均收敛代价	成功率 (%)	平均时间 (ms)	标准差
1/3/3/4/2	Map 1	351.44	351.44	100	9.1	0	3/3/4/4/2	Map 1	351.44	351.44	100	24.9	0
	Map 2	620.15	620.34	80	148.0	0.44		Map 2	620.15	620.15	100	309.0	0
	kroB100	22141.00	22145.03	92.5	250.5	14.66		kroB100	22141.00	22142.45	97.5	350.1	9.17
2/3/3/4/2	Map 1	351.44	351.44	100	15.1	0	3/3/5/4/2	Map 1	351.44	351.44	100	28.1	0
	Map 2	620.15	620.27	85	204.7	0.29		Map 2	620.15	620.15	100	356.3	0
	kroB100	22141.00	22143.90	95	254.8	12.80		kroB100	22141.00	22141.00	100	407.1	0
3/3/3/4/2	Map 1	351.44	351.44	100	27.2	0	3/3/3/1/2	Map 1	351.44	351.44	100	32.1	0
	Map 2	620.15	620.15	100	241.5	0		Map 2	620.15	620.15	100	355.5	0
	kroB100	22141.00	22142.45	97.5	347.9	9.17		kroB100	22141.00	22141.00	100	474.8	0
4/3/3/4/2	Map 1	351.44	351.44	100	40.4	0	3/3/3/2/2	Map 1	351.44	351.44	100	40.0	0
	Map 2	620.15	620.15	100	371.1	0		Map 2	620.15	620.17	97.5	344.4	0.13
	kroB100	22141.00	22141.00	100	480.5	0		kroB100	22141.00	22141.00	100	421.5	0
5/3/3/4/2	Map 1	351.44	351.44	100	52.7	0	3/3/3/3/2	Map 1	351.44	351.44	100	27.5	0
	Map 2	620.15	620.15	100	336.3	0		Map 2	620.15	620.15	100	272.8	0
	kroB100	22141.00	22142.45	97.5	628.7	9.17		kroB100	22141.00	22142.45	97.5	357.8	9.17
3/1/3/4/2	Map 1	351.44	351.44	100	37.8	0	3/3/3/5/2	Map 1	351.44	351.44	100	21.7	0.02
	Map 2	620.15	620.17	97.5	426.5	0.13		Map 2	620.15	620.21	92.5	211.6	0.22
	kroB100	22141.00	22141.00	100	548.4	0		kroB100	22141.00	22145.35	92.5	342.0	15.47
3/2/3/4/2	Map 1	351.44	351.44	100	27.2	0	3/3/3/4/1	Map 1	351.44	351.44	100	37.8	0
	Map 2	620.15	620.15	100	311.8	0		Map 2	620.15	620.17	97.5	217.8	0.13
	kroB100	22141.00	22141.00	100	475.7	0		kroB100	22141.00	22193.30	30	786.8	37.45
3/4/3/4/2	Map 1	351.44	351.44	100	30.5	0	3/3/3/4/3	Map 1	351.44	351.44	100	33.8	0
	Map 2	620.15	620.19	95	257.0	0.18		Map 2	620.15	620.15	100	243.2	0
	kroB100	22141.00	22143.90	95	296.7	12.80		kroB100	22141.00	22143.90	95	404.3	12.80
3/5/3/4/2	Map 1	351.44	351.44	100	38.5	0	3/3/3/4/4	Map 1	351.44	351.44	100	33.5	0
	Map 2	620.15	620.75	62.5	232.1	1.17		Map 2	620.15	620.17	97.5	286.0	0.13
	kroB100	22141.00	22180.55	50	351.7	42.06		kroB100	22141.00	22142.45	97.5	390.8	9.17
3/3/1/4/2	Map 1	351.44	351.44	100	44.4	0	3/3/3/4/5	Map 1	351.44	351.44	100	28.3	0
	Map 2	620.15	620.71	65	217.1	1.05		Map 2	620.15	620.19	95	287.7	0.18
	kroB100	22141.00	22157.05	80	365.4	35.39		kroB100	22141.00	22142.45	97.5	487.7	9.17
3/3/2/4/2	Map 1	351.44	351.44	100	32.2	0							
	Map 2	620.15	620.35	75	247.2	0.35							
	kroB100	22141.00	22143.40	95	294.5	10.83							




图 10. 各参数水平在 Map 1、Map 2、kroB100 上的代价与计算时间对比。

影响最小——这与其作为纯计算加速器的角色一致——同时提供运行时间收益。综上，所提算法的性能可归因于以下关键因素：其一，VND 局部搜索系统性地精化回路，是逼近最优代价的主要来源；其二，MMAS 信

息素边界抑制过早收敛，维持了种群多样性；其三，伪随机转移、S 形调度与候选列表剪枝则主要提升收敛速度并降低计算开销。消融收敛曲线、代价分布与平均代价/时间对比分别如图 12–14 所示。




图 11. 默认参数设置下算法在 Map 1、Map 2、kroB100 上规划的路径图。

表 V
消融实验分组

组别	描述	禁用机制
1	完整算法	无
2	无伪随机	ACS 伪随机转移规则
3	无 VND	VND 局部搜索
4	无 S 曲线	渐进局部搜索调度
5	无候选列表	候选列表加速
6	无 MMAS	MMAS 信息素边界

E. 不同旅行商求解器的多目标点遍历对比

本组实验通过将改进 A* 规划器（结合虚拟节点法）与不同旅行商求解器结合，评估完整的多目标点遍历框架，并将所提蚁群优化求解器（MMAS-VND-CL）与基线旅行商元启发式方法进行对比。

实验选取四个旅行商求解器——所提 MMAS-VND-CL、标准蚁群系统（ACO）、遗传算法（GA）和模拟退火（SA）——分别与改进 A* 规划器结合，在所有三张地图上求解多目标点遍历问题。每个求解器的参数汇总于表 VII。每种组合在每张地图上运行 40 次。MMAS-VND-CL 的完整参数为：蚂蚁数 $m = 40$ ， $\alpha = 1$ ， $\beta = 2$ ， $\rho = 0.25$ ， $Q = 225$ ， $\tau_0 = 0.1$ ，最大迭代 200， $q_0 = 0.45$ ， $y_{\max} = 0.4$ ，转换区间 $[0, 30]$ ，精英比率 $r_{\text{elite}} = 0.7$ ，候选列表大小 $k = 9$ 。

每个求解器的多目标点遍历性能见表 VIII。对应可视化结果见图 15–18。

对比结果表明，所提 MMAS-VND-CL 求解器在所有地图上均显著优于三个基线。在 kroB100（最优代价

22141）上，所提求解器以 97.5% 的命中率达到最优代价，平均代价为 22142.45，而最优基线（ACO）的平均代价为 24435.83——退化 10.4%——且从未命中最优代价。GA 表现最差，kroB100 上平均代价 37360.65，高于最优 68.7%。性能差距在稳定性方面更为显著：所提求解器的标准差（9.17）比 GA（2680.12）小 60 倍以上，比 SA（752.52）小 82 倍以上，展现出卓越的可靠性。Map 1 和 Map 2 上 100% 的命中最优率表明所提求解器在这两个环境中稳定找到全局最优，而所有基线均从未命中最优。在计算时间方面，所提求解器与 ACO 相当（kroB100 上 0.35 s 对比 0.33 s），显著快于 GA（4.99 s），尽管包含了 VND 局部搜索——此收益归功于候选列表加速。上述结果表明，在统一的 JPS 代价矩阵接口下，将虚拟节点编码与候选列表加速的 MMAS-VND 局部搜索相结合，能够在障碍环境多目标点遍历任务中同时获得更优的解质量、更高的可靠性与可接受的计算开销。收敛曲线、代价分布、平均代价/时间以及最优路径分别如图 15–18 所示。

VI. 结论


本文提出了一种面向障碍环境多目标点遍历路径规划的协同优化框架，将基于跳点搜索的改进 A* 全局规划器与面向开放旅行商问题的改进蚁群优化求解器相集成。该框架解决了文献中的一个实际空白：传统旅行商研究假设无约束的欧氏距离，而标准路径规划算法仅优化单对路由。通过全局规划器将障碍信息编码为代价矩阵，并通过蚁群优化求解器求解所得开放旅行商问题，该框架将几何推理与组合推理统一到单一管线中。

在路径规划阶段，跳点搜索（JPS）利用均匀代价栅格中的对称性剪枝冗余节点，仅在路径方向改变或出现强制选择处扩展，从而在保持最优性的同时大幅缩小搜索树。安全感知的路径简化通过拐点提取、贪心正向扫描、中间点探索与路径对比生成最小安全航点子集；弧长参数化三次样条平滑进一步将简化折线转化为适合物理机器人执行的连续轨迹。


在序列优化阶段，改进蚁群优化求解器集成了六个机制。虚拟节点法将开放旅行商问题转化为标准闭环旅行商问题，使起点与终点完整参与信息素更新与局部搜索；具有动态边界的最大-最小蚁群系统信息素管理抑制过早收敛并维持探索多样性；蚁群系统风格的伪随机转移规则在受控贪心与随机探索之间取得平衡；候选列表加速的可变邻域下降将局部搜索复杂度由 $O(K^2)$ 降

表 VI
消融实验结果


组别	地图	最优代价	中位代价	平均代价	成功率 (%)	平均时间 (s)	代价极差	标准差
1	Map 1	351.4406	351.4406	351.4406	100	0.0272	0	0
	Map 2	620.1509	620.1509	620.1509	100	0.2415	0	0
	kroB100	22141.0000	22141.0000	22142.4500	97.5	0.3479	58.00	9.1706
2	Map 1	351.4406	351.4406	351.4406	100	0.0324	0	0
	Map 2	620.1509	620.1509	620.1509	100	0.4157	0	0
	kroB100	22141.0000	22141.0000	22141.0000	100	0.7313	0	0
3	Map 1	351.4406	351.4406	352.5747	67.5	0.1339	9.7568	2.2744
	Map 2	620.9552	620.1509	632.6061	2.5	0.5695	37.4366	8.7702
	kroB100	22279.0000	22512.0000	22566.9750	0	1.4739	1012.0000	239.4130
4	Map 1	351.4406	351.4406	351.4406	100	0.0175	0	0
	Map 2	620.1509	620.1509	620.1711	97.5	0.3494	0.8042	0.1272
	kroB100	22141.0000	22141.0000	22146.8000	90	0.6570	58.0000	17.6217
5	Map 1	351.4406	351.4406	351.4406	100	0.0325	0	0
	Map 2	620.1509	620.1509	620.1509	100	0.3325	0	0
	kroB100	22141.0000	22141.0000	22143.9000	95	0.4260	58.0000	12.8018
6	Map 1	351.4406	353.2976	359.6359	30	0.0218	45.0453	12.4797
	Map 2	620.1509	624.1322	626.1160	10	0.0854	24.7496	6.1209
	kroB100	22141.0000	22141.0000	22166.6500	70	0.2484	235.0000	47.4933



(a) Map 1




(b) Map 2




(c) kroB100


图 12. 六个消融组在三张地图上 40 次运行的平均迭代次数-代价收敛曲线。



(a) Map 1



(b) Map 2



(c) kroB100

图 13. 六个消融组在三张地图上 40 次运行的代价分布 (箱线图)。

至 $O(K \cdot k)$, 使超过 100 个目标点实例上的密集邻域搜索成为可能; S 形渐进调度在迭代过程中逐步由探索转向利用; 基于种群同质性与最优解停滞的自适应停止准则则避免无效计算。

实验从路径长度、计算时间、扩展节点数、收敛代价、成功率与标准差等指标验证了上述设计。基于 JPS

的规划器相较 Dijkstra 和标准 A* 最多减少 83% 的节点扩展 (Map 3 上 48 个对比 566 个), 在 Map 2 上将规划时间由 202.29 ms 降至 11.85 ms, 并取得更短路径。参数敏感性分析表明默认超参数处于均衡区, 其中贪心概率 q_0 与后期局部搜索比例 $y_{\max}$ 最为敏感。消融实验呈现出清晰的组件层次: VND 局部搜索与 MMAS




图 14. 六个消融组在三张地图上的平均代价与平均计算时间对比。




图 15. 四个旅行商求解器在三张地图上 40 次运行的平均时间-代价收敛曲线。




图 16. 四个旅行商求解器在三张地图上 40 次运行的代价分布（箱线图）。




图 17. 四个旅行商求解器在三张地图上的平均代价与平均计算时间对比。

信息素边界共同支撑解质量，禁用任一组件会使成功率由近 100% 降至 30% 以下；伪随机转移、S 形调度与候选列表则主要改善收敛速度与计算效率。在多目标点遍历对比中，所提 MMAS-VND-CL 求解器在 kroB100 上

以 97.5% 的命中率达到最优代价（平均代价 22142.45），较最优基线标准蚁群优化（平均代价 24435.83）改善约 10.4%，且标准差比遗传算法小一个数量级以上，体现出良好的稳定性。




图 18. 各旅行商求解器在 Map 1、Map 2、kroB100 上规划的最优代价路径图。

本文工作仍有若干局限，亦指明了后续研究方向。第一，当前框架假设障碍地图静态且完全已知，面向任务执行中动态出现或移动的障碍物尚需在线重规划机制；第二，地图表示限于二维栅格，扩展至含高程约束的三维地形有望拓宽其在空中与水下平台上的适用性；第三，候选列表规模 k 等超参数目前固定不变，自适应或基于学习的参数控制有望进一步提升跨实例泛化能力；第四，框架目前面向单机机器人任务，若扩展到多机器人协同多目标点遍历（共享目标集并避免机器人间碰撞），将具有更强的实用价值；第五，完整 $O(N^2)$ 代价矩阵在目标规模很大时计算开销较高，可借助距离预言机近似或增量代价精化加以缓解。

致谢

感谢相关实验环境与开源实现对本研究的支持（待补充具体致谢对象）。

参考文献

- [1] S. B. Liu et al., "SMUG planner: A safe multi-goal planner for mobile robots in challenging environments," *IEEE Robot. Autom. Lett.*, vol. 8, no. 9, pp. 5504–5511, 2023.
- [2] H. T. T. Binh, "Fast marching firework method for multi-goal mobile robot path planning in complex obstacle maps," *Intell. Service Robot.*, vol. 18, 2025, doi: 10.1007/s11370-025-00654-6.
- [3] C.-G. Wu, Y.-C. Liang, H.-P. Lee, C. Lu, and C. Lin, "Solving constrained traveling salesman problems by genetic algorithms," *Prog. Nat. Sci.*, vol. 14, no. 7, pp. 631–637, 2004.

表 VII
对比旅行商求解器的参数设置

算法	参数
MMAS-VND-CL	$n_{\text{ants}} = 40$; $\alpha = 1$; $\beta = 2$; $\rho = 0.25$; $Q = 225$; $\tau_0 = 0.1$; 贪心选择概率 $q_0 = 0.45$; 局部搜索比例 $y_{\text{max}} = 0.4$; 局部搜索过渡区间 $= [0, 30]$; 局部搜索精英蚂蚁占比 $r_{\text{elite}} = 0.7$; 候选邻居数 $k = 9$
ACO	$n_{\text{ants}} = 40$; $\alpha = 1$; $\beta = 2$; $\rho = 0.25$; $Q = 225$; $\tau_0 = 0.1$; Iter = 100
GA	Pop = 100; Iter = 1500; $P_c = 0.8$; $P_m = 0.25$; 精英保留数量 = 10
SA	$T_0 = 150$; $\alpha = 0.996$; $L = 10$; $T_{\text{end}} = 10^{-8}$

- [4] “A survey on approximability of traveling salesman problems using the TSP-T3CO definition scheme,” *Ann. Oper. Res.*, 2025, doi: 10.1007/s10479-025-06641-5.
- [5] P. E. Hart, N. J. Nilsson, and B. Raphael, “A formal basis for the heuristic determination of minimum cost paths,” *IEEE Trans. Syst. Sci. Cybern.*, vol. 4, no. 2, pp. 100–107, 1968.
- [6] E. W. Dijkstra, “A note on two problems in connexion with graphs,” *Numer. Math.*, vol. 1, no. 1, pp. 269–271, 1959.
- [7] S. M. LaValle, “Rapidly-exploring random trees: A new tool for path planning,” Dept. Comput. Sci., Iowa State Univ., Ames, IA, USA, Tech. Rep. 98-11, 1998.
- [8] “A comprehensive review of improved A* path planning algorithms and their hybrid integrations,” *Automation*, vol. 6, p. 52, 2025.
- [9] L. H. O. Rios and L. Chaimowicz, “A survey and classification of A* based best-first heuristic search algorithms,” in *Proc. 20th Brazilian Symp. Artif. Intell. (SBIA)*, 2010, pp. 253–262.
- [10] M. Likhachev, G. Gordon, and S. Thrun, “ARA*: Anytime A* with provable bounds on sub-optimality,” in *Adv. Neural Inf. Process. Syst. (NIPS)*, 2003, pp. 767–774.
- [11] D. Harabor and A. Grastien, “Online graph pruning for pathfinding on grid maps,” in *Proc. 25th AAAI Conf. Artif. Intell. (AAAI-11)*, 2011, pp. 1114–1119.
- [12] D. Harabor and A. Grastien, “Improving jump point search,” in *Proc. 24th Int. Conf. Automated Planning Scheduling (ICAPS-14)*, 2014, pp. 128–135.
- [13] “Improved JPS and DWA path planning algorithm for mobile robots,” *Expert Syst. Appl.*, 2026.
- [14] “Research on mobile robot path planning based on an improved bidirectional jump point search algorithm,” *Electronics*, vol. 14, no. 8, p. 1669, 2025, doi: 10.3390/electronics14081669.
- [15] “Adaptive weight optimization based jump point Theta* algorithm in mobile robot path planning for intricate environments,” *Discover Appl. Sci.*, vol. 7, p. 11, 2025, doi: 10.1007/s42452-025-07932-z.
- [16] “UGV path optimization in UAV-assisted environments using visibility-aware path simplification,” *J. Sens. Actuator Netw.*, vol. 15, no. 3, p. 41, 2025.
- [17] “Enhancing the safety and smoothness of path planning through an integration of Dijkstra’s algorithm and piecewise cubic Bezier optimization,” *Expert Syst. Appl.*, 2025.
- [18] “Adaptive A*/NSGA-II framework for multi-goal navigation of mobile robots,” *Meas. Sci. Technol.*, 2025, doi: 10.1088/1361-6501/ae9209.
- [19] J. H. Holland, *Adaptation in Natural and Artificial Systems*. Ann Arbor, MI, USA: Univ. Michigan Press, 1975.
- [20] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, “Optimization by simulated annealing,” *Science*, vol. 220, no. 4598, pp. 671–680, 1983.
- [21] M. Dorigo, V. Maniezzo, and A. Colnori, “Ant system: Optimization by a colony of cooperating agents,” *IEEE Trans. Syst., Man, Cybern. B*, vol. 26, no. 1, pp. 29–41, 1996.
- [22] M. Dorigo and L. M. Gambardella, “Ant colony system: A cooperative learning approach to the traveling salesman problem,” *IEEE Trans. Evol. Comput.*, vol. 1, no. 1, pp. 53–66, 1997.
- [23] T. Stützle and H. H. Hoos, “MAX-MIN ant system,” *Future Gener. Comput. Syst.*, vol. 16, no. 8, pp. 889–914, 2000.
- [24] P. Hansen and N. Mladenović, “Variable neighborhood search: Principles and applications,” *Eur. J. Oper. Res.*, vol. 130, no. 3, pp. 449–467, 2001.
- [25] N. A. Kyriakakis, M. Marinaki, and Y. Marinakis, “A hybrid ant colony optimization–variable neighborhood descent approach for the cumulative capacitated vehicle routing problem,” *Comput. Oper. Res.*, vol. 134, p. 105397, 2021.
- [26] “An improvement to the 2-opt heuristic algorithm for approximation of optimal TSP tour,” *Appl. Sci.*, vol. 13, no. 12, p. 7339, 2023, doi: 10.3390/app13127339.
- [27] “Matrix-based ant colony system for traveling salesman problem,” in *Proc. IEEE Int. Conf. Syst., Man, Cybern. (SMC)*, 2024.
- [28] “nLKH-ACS: A niching Lin-Kernighan–Helsgaun-based ant colony system for multisolution traveling salesman problems,” *IEEE Trans. Evol. Comput.*, 2024.
- [29] “CAACS: A carbon aware ant colony system,” *Sci. Rep.*, 2025.
- [30] “Ant colony optimization for multiple traveling salesmen problem with revisitable cities,” in *Proc. IEEE*, 2024.
- [31] B. Yao, Q. Hu, L. Zhang, and J. Tian, “Improved ant colony optimization for seafood product delivery routing problem,” *Promet–Traffic Transp.*, vol. 26, no. 1, 2014.
- [32] B. Yao, C. Chen, X. Song, and X. Yang, “Fresh seafood delivery routing problem using an improved ant colony optimization,” *Ann. Oper. Res.*, vol. 273, no. 1–2, pp. 163–186, 2019, doi: 10.1007/s10479-017-2531-2.

表 VIII
多目标点遍历对比结果

算法	地图	最优代价	中位代价	平均代价	命中最优率 (%)	平均时间 (s)	代价极差	标准差
MMAS-VND-CL (本文)	Map 1	351.4406	351.4406	351.4406	100	0.0272	0	0
	Map 2	620.1509	620.1509	620.1509	100	0.2415	0	0
	kroB100	22141.0000	22141.0000	22142.4500	97.5	0.3479	58.00	9.1706
ACO	Map 1	359.3170	388.5591	388.6513	0	0.0564	59.3454	15.5736
	Map 2	638.6843	688.3238	685.7453	0	0.1304	88.0149	18.9081
	kroB100	23359.0000	24418.5000	24435.8250	0	0.3300	2045.0000	559.3037
GA	Map 1	404.4468	482.2940	485.1563	0	3.0007	201.4194	44.2581
	Map 2	698.4059	859.9173	851.2521	0	3.8424	221.8002	46.5627
	kroB100	33271.0000	37285.5000	37360.6500	0	4.9882	14912.0000	2680.1153
SA	Map 1	359.9775	394.8159	390.3485	0	0.3902	44.3223	13.9440
	Map 2	664.5622	688.7545	691.9980	0	0.7321	17.4566	66.3322
	kroB100	23574.0000	24817.5000	24918.3500	0	0.3218	2841.0000	752.5199